113學年度臺中市中小學科學展覽會

作品說明書

科　　別：電腦與資訊學科

組　　別：高級中等學校組

作品名稱：「羽」你同行－基於多模態深度學習與大語言模型的手機端羽毛球姿態矯正系統

關 鍵 詞：羽毛球姿勢矯正、多模態分析、AI教練

編　　號：

摘要

隨著台灣在奧運羽球雙打連續獲第二面金牌後，越來越多台灣人想嘗試這項運動。為提升新手的學習效率，本研究旨在開發一套能協助新手透過手機就可進行姿態矯正的軟體。首先，本研究選擇BlazePose，因腳與手腕有更多關節點資訊有利分類姿勢。接著再訓練MLP、KNN及YOLO姿勢分類器，其中KNN分類器在影片分類可達97.33%的準確率。此外，本研究也嘗試設計 BIBO 流程可追蹤羽球自動剪輯影片，準確率95.89%。經由上述多模態分析再檢查常見錯誤姿勢及與專家姿勢差異，LLM 最終整合生成姿勢矯正建議。最後羽球專家對於本研究生成的姿勢矯正建議的平均認同分數達83.33分。

壹、前言

一、研究動機

羽毛球新手提升技能通常有三種方法，球場實戰對打訓練、聘請專業教練指導或觀看 YouTube 影片學習。由於羽毛球人工智慧教練軟體尚未普及，且相關研究尚未提供羽毛球新手姿勢指導功能，初學者無法即時調整動作而影響學習表現。

因此，本研究想嘗試研究輔助羽毛球新手的姿勢矯正軟體，其中結合物件偵測與追蹤技術來分析新手表現，檢查常見新手錯誤姿勢清單與專家姿勢比對，最後也嘗試結合大型語言模型 (Large Language Model, LLM)，提供羽毛球新手有效的指導建議。此外，本研究也希望可僅利用一般手機與腳架來架設此軟體，讓更多使用者都可方便操作與執行。

二、研究目的

本研究旨在發展一套羽毛球 AI 教練軟體，結合不同類神經網路模型，利用手機紀錄新手的動作姿勢影像進行電腦視覺分析，最後可依據新手常見錯誤姿勢檢查錯誤，並結合大語言模型 (LLM)給予新手建議。

(一)探討人體姿態辨識模型及機器學習技術應用在羽毛球姿勢分類。

(二)設計並實作 BIBO 方法應用於精確識別羽毛球動作分類的最佳時機。

(三)研究如何整合各 AI 模型的分析結果並給予新手完善的姿勢建議。

三、文獻回顧

(一)羽毛球新手主要的學習姿勢

新手主要學習的姿勢有長球、平球、挑球、放網與發球(VictorSport, n.d.)，以下為研究者示範這五類動作的連續影像。

1.長球(clear)：常用於調動對手或擠壓對手空間。

圖1-1 長球

2.平球(drive)：具攻擊性的技術。通常出現在接殺球的那一拍。

圖1-2 平球

3.挑球(lift)：常出現於低於擊打腰部以下的球。

圖1-3 挑球

4.放網(net)：可以調動對手也可引導對手起高球，方便攻擊。

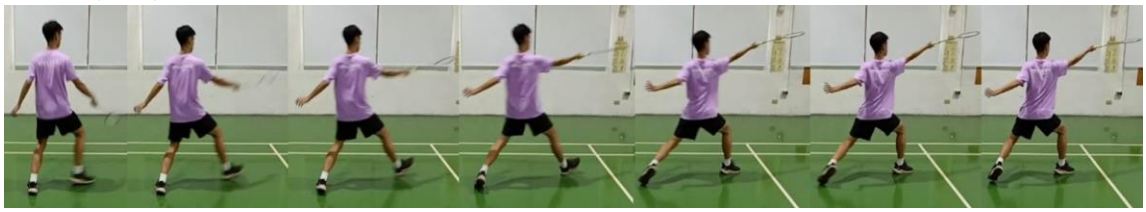

圖1-4 放網

5.發球(serve)：在比賽開始時引導比賽的展開。

圖1-5 發球

(二)羽毛球新手常見的錯誤姿勢

錯誤姿勢可能會影響擊球的準確性、穩定性以及增加受傷的風險。表1-1 是研究者示範並整理出的業餘選手在姿勢上常見的錯誤。

表1-1 羽毛球新手常見的錯誤姿勢

姿勢	錯誤姿勢項目	圖示	詳細解說
長球 (clear)	1.側身不完全		身體轉動幅度不夠，無法有效利用身體力量帶動擊球。
	2.輔助手蜷縮		手臂無伸展，手臂與身體夾腳<90度、手臂夾腳<70度，無法有效利用身體帶動擊球。
	3.擊球手位置過低		大臂和身體夾角過小，無法在最高點擊球。
平球 (drive)	1.球拍未舉起	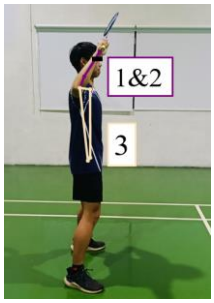	擊球後，球拍隨即放下，未能立刻抬起以準備下一球。
	2.身體直立		身體沒有稍微前傾壓低重心預備
挑球 (lift)	1.膝蓋超伸	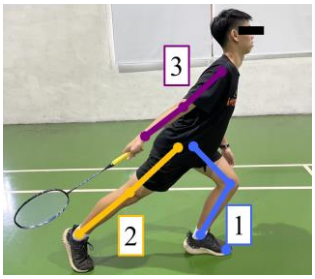	膝蓋超出腳尖，腿部夾腳<90度，身體壓力集中在膝蓋上。
	2.無慣用腳在前		擊球手和前腳不同
	3.擊球手引拍過大		擊球前向後引拍過大
放網 (net)	1.手臂蜷縮	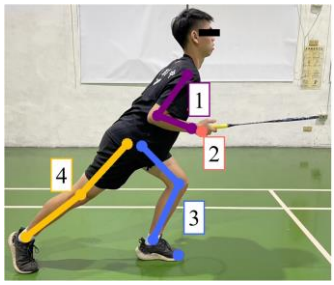	球拍距離身體太近沒有伸展，手臂夾角<120度。
	2.出手點過低		球拍低於胸口，沒有在高點擊球。
	3.膝蓋超伸		膝蓋超出腳尖且腿部夾腳<90度
	4.無慣用腳在前		擊球手和前腳不同
發球 (serve)	1.無慣用腳在前	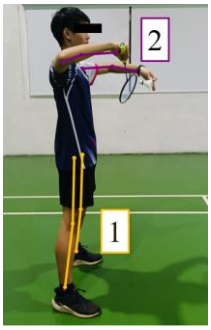	發球時必須慣用腳在前，非慣用腳在後。
	2.發球位置不當		發球時擊球點應位於腰部附近。

(三) AI 技術應用於羽毛球運動的研究

目前 AI 技術應用於羽毛球專案與論文主要可分為兩類：第一類是羽球比賽數據分析，例如最長來回球次數、球速及羽球落點追蹤；第二類是羽毛球姿勢的分類，進而探討比賽策略。查詢的文獻中目前尚無提供羽毛球新手姿勢指導功能的研究。表1-2 為研究者依據相關因素綜合整理。

表1-2 目前AI技術應用於羽毛球之相關研究主題

專案/論文	作者	年份	IOT裝置及其種類	攝影機架設角度	是否用於賽事分析	姿勢分類及方法
Clutch：AI for Racket Sports	Kári Gunnarsson	2021	否	正後方	是	是(未公開)
TrackNet： A Deep Learning Network for Tracking High-speed and Tiny Objects in Sports Applications	Yu-Chuan Huang et al.	2019	否	正後方	是	否
Badminton Coach AI：基於深度學習之羽球賽事資訊分析平台	王威堯 et al.	2020	否	正後方	是(球種分類)	是(SVM、RF、XGBoost)
智能球拍	成大與逢甲共同研發	2020	是(陀螺儀)	無攝影機	否	否
基於人體姿勢估計與機器學習的羽球球種分類研究	Shiela Mecha Cabahug	2022	否	正前方	否	是(CNN、LSTM、CNN-LSTM)
Deep Learning Based Technical Classification of Badminton Pose with Convolutional Neural Networks	Tukino et al.	2024	否	正後方、側邊	否	是(CNN)
AI coach for badminton	Dhruv Toshniwal et al.	2022	是(IMU、Opal、XiaoYu 2.0感測器)	正後方	否	是(揮拍軌跡來做姿勢分類)

貳、研究設備與器材

一、研究硬體

(一)電腦

1.CPU：Intel® Core™ Ultra 9 285K

2.GPU：Nvidia Geforce RTX 4060 Ti 16GB

(二)羽毛球

(三)球拍

(四)手機 (型號：OPPO RENO 12 F)

(五)手機腳架

二、研究軟體

(一)Python (版本：3.10.9) – 實驗主要程式撰寫語言。

(二)opencv-python (版本：4.10.0.84) – 負責影片的讀取、分割、預處理。

(三)pandas (版本：2.2.2) – 讀取CSV檔案。

(四)mediapipe (版本：0.10.14) – 人體骨架座標點追蹤函式庫。

(五)ultralytics (版本：8.2.56) – YOLOv11 物件偵測模型的函式庫。

(六)numpy (版本：1.26.4) – 數學運算函式庫，負責處理實驗數據的中心化。

(七)matplotlib (版本：3.9.1) – 實驗資料視覺化的函式庫，用於繪製圖表。

(八)tensorflow (版本：2.17.0) – 開源的深度學習框架，實驗用於深度學習模型訓練。

(九)scikit-learn (版本：1.5.1) – 開源機器學習庫以及產生模型指標報告。

(十)seaborn (版本：0.13.2) – 負責混淆矩陣的生成。

(十一)openai (版本：1.38.0) – 負責姿勢提供建議API，可以連線得到ChatGPT-4。

(十二)TensorRT (版本：10.8.0.43) – 負責YOLO模型的量化。

(十三)joblib (版本：1.4.2) – 負責儲存訓練好的模型。

(十四)time – 負責計算時間。

(十五)os – 負責資料的搬移。

(十六)csv – 負責將姿勢數據儲存為CSV檔案。

(十七)CVAT – Computer Vision Annotation Tool，資料標記工具。

叁、研究過程及方法

一、研究架構

此研究架構分為三個部分：資料蒐集+預處理、模型訓練、以及系統整合。

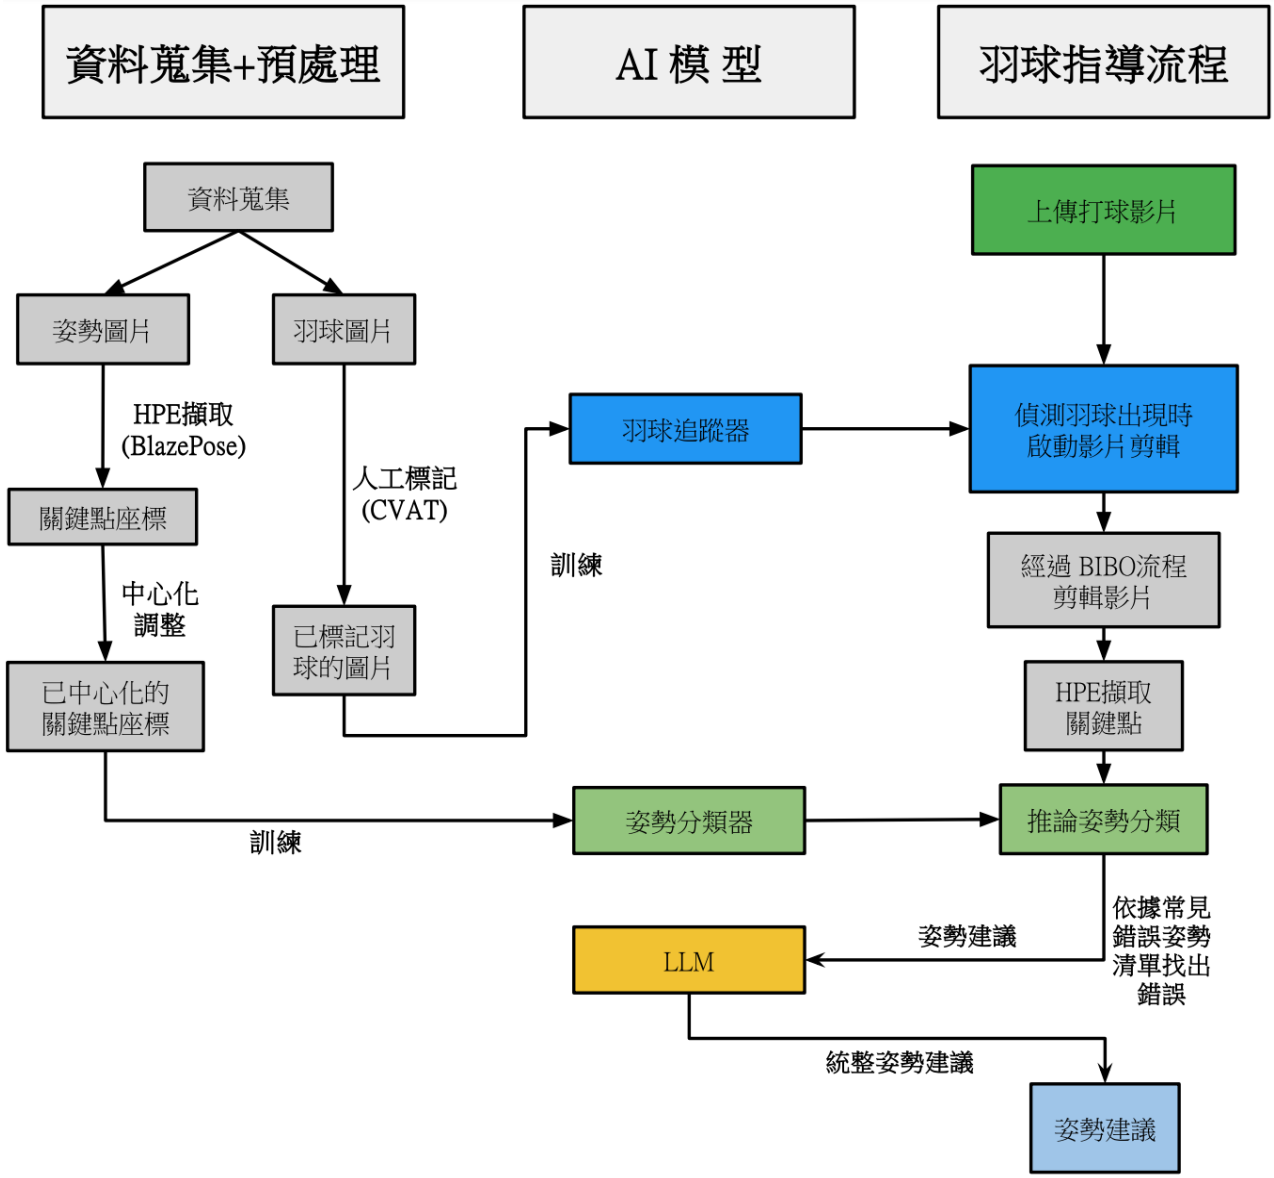

圖3-1 研究架構

二、相機類型和位置

有別於其他 AI 技術應用於羽毛球研究，大多採可覆蓋全場約兩米高的攝影機腳架或壁掛式攝影機，這類攝影設備對羽毛球新手而言，設置與操作相對不易。

(一)採用手機作為攝影工具

考量現今人人幾乎都有手機，只需再一手機腳架就可錄製並接收調整姿勢建議。

(二)相機架設位置

如圖 3-2所示，相機放置於距中線 220 公分及右發球線的 60 公分處，相機高度需設置離地 150 至 180 公分間。紅色五面體為本研究最佳的攝影範圍。黑線為球網，紫色圓形代表羽毛球新手站立位置，對側場地可搭配發球機或朋友練習。如此設計縮小羽毛球新手活動範圍，適合進行基礎訓練。

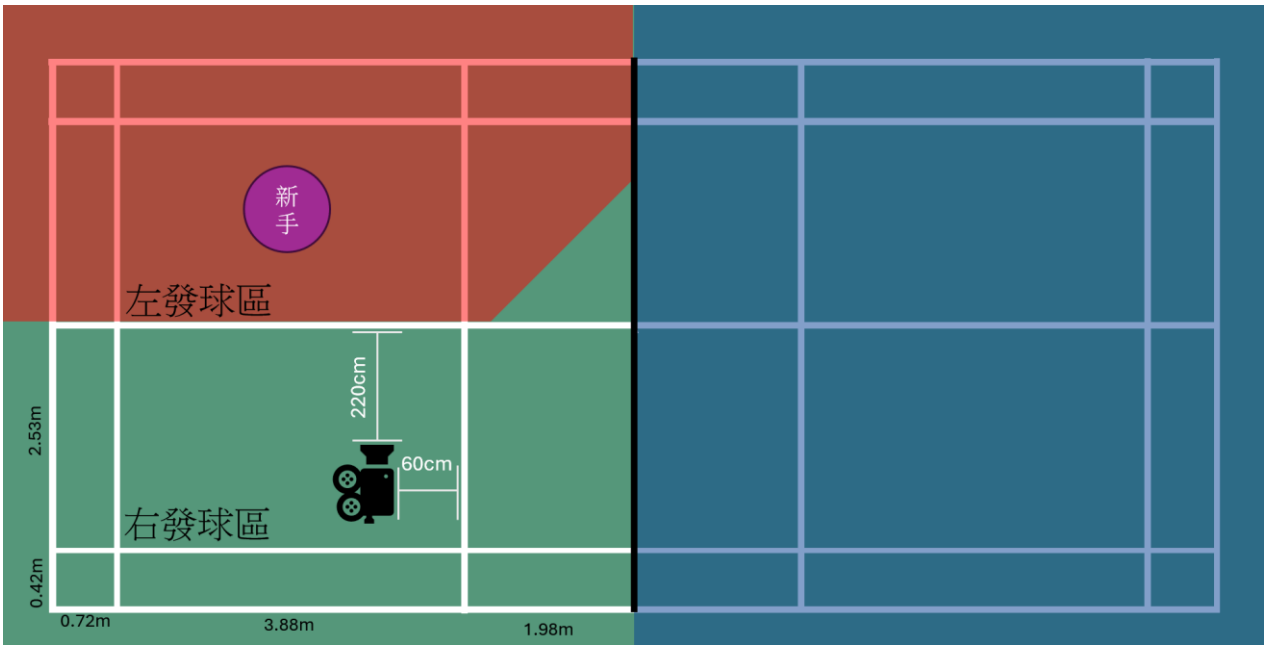

圖3-2 攝影機架設示意圖

三、資料蒐集與預處理

本研究所使用的羽毛球圖片與人體骨架座標點序列資料皆在本校羽毛球場由研究者自行蒐集。60% 含羽毛球的球員打球圖片 (3,322張)使用壓克力顏料標記，40% 含羽毛球的球員打球圖片 (2,216張)是原始白色羽毛球。如圖3-5首先利用 opencv-python 套件擷取影片幀後，再透過 CVAT 標註羽毛球邊界框 (class, x, y, w, h) (參見圖3-3)。

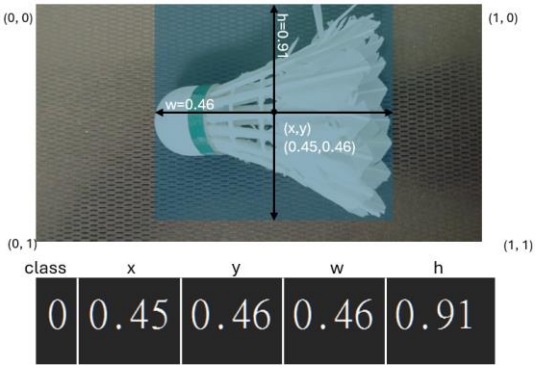

圖 3-3 YOLO標記格式

校隊選手及羽毛球新手的人體骨架座標點序列資料，五種姿勢各超過 3,000 張圖片 。如圖3-5，先使用 BlazePose 模型對姿勢圖片提取座標點 {(x0, y0), ...(x32, y32)}，接著移除臉部座標點 (1-10 號)，僅保留 0 號座標點 (鼻子) 作為頭部中心指標。接著透過程式自動將座標點連結為骨架資料，並檢視及移除不完整的姿勢骨架訓練圖片 ，確保姿勢預測分類功能的準確性。如圖3-4 表格的最後一欄標記為羽球 Pose標籤欄位，共47個欄位最後再保存為 CSV 格式檔案。

x0	y0	x11	y11
0.173037	0.400072	0.167325	0.450643
0.168423	0.404677	0.15833	0.447687
0.425332	0.391913	0.423283	0.442546

……

x31	y31	x32	y32	Pose
0.21604	0.71432	0.28204	0.70592	long
0.21319	0.71295	0.27487	0.70544	long
0.21493	0.71462	0.21828	0.71228	long

圖 3-4 座標點座標資料示意圖

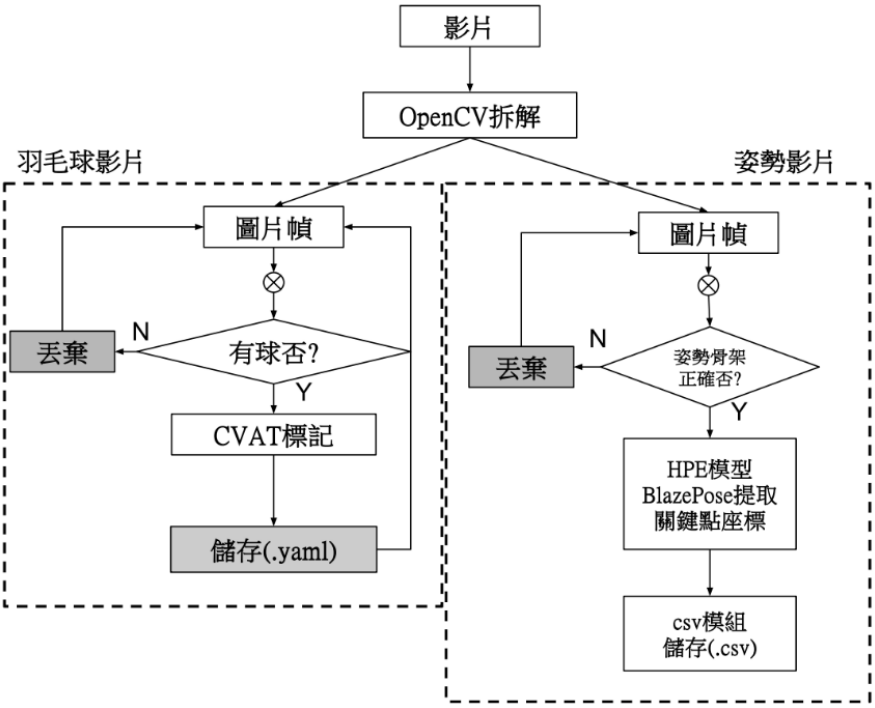

圖 3-5 資料收集及預處理流程圖

以下是使用 CVAT 平台標記羽球圖片，用於訓練羽毛球追蹤器，其中「ball」指的是羽毛球。即使羽毛球看起來是灰色模糊的(motion blur)，研究者仍然對其進行標註。

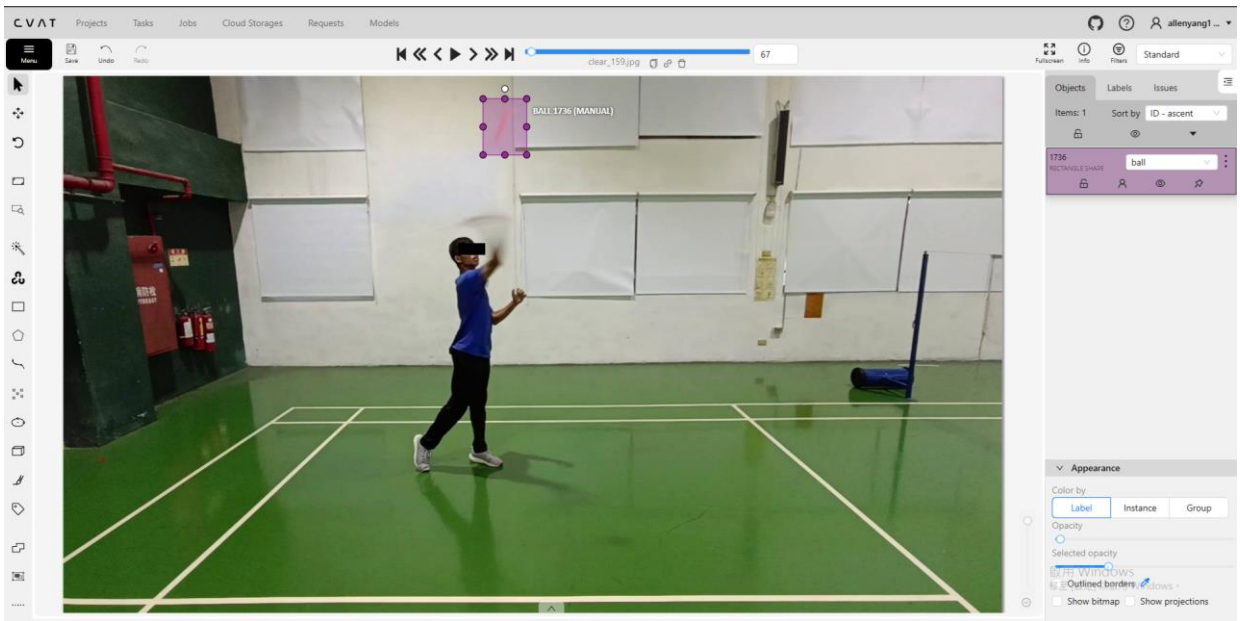

圖 3-6 利用 CVAT 標記羽球圖片(來源：CVAT)

關於新手羽毛球姿勢骨架座標點序列資料共計 19,885 筆。「其他」類包含選手站立、轉身或蹲下等動作，旨在幫助模型更準確區分不同姿勢。

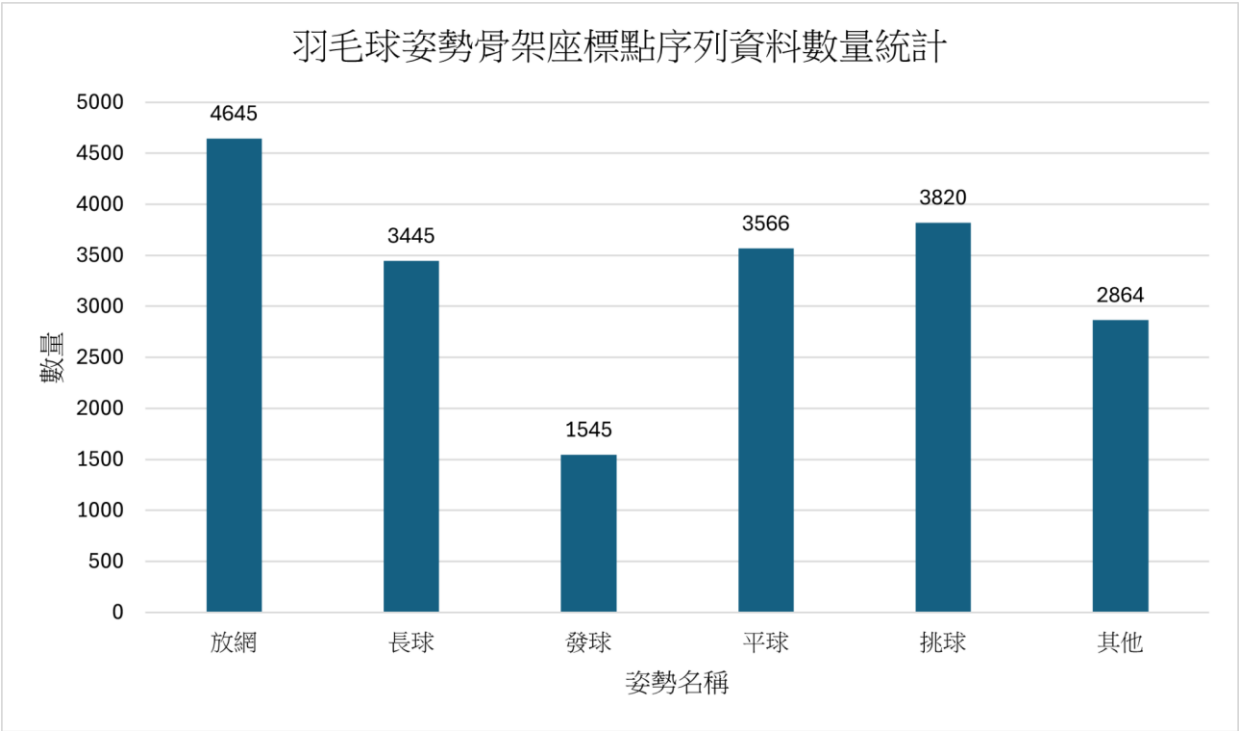

圖 3-7 羽毛球姿勢骨架座標點序列數量統計

四、探討人體姿態辨識模型及機器學習技術應用在羽毛球姿勢分類

(一)HPE模型選擇

如表 3-1 所示，比較 BlazePose、YOLO v11-pose 和MoveNet-lightning 三種常見姿勢估計模型其準確率與推論時間。研究者準備 300 張羽毛球姿勢圖片 進行評估，座標點位置標示正確的的比例若大於 80% 視為高準確率，若小於 80% 且大於 60% 視為中準確率，低於 60% 則視為低準確率。標註正確則視關節點與圖片是否有對齊及關節點是否繪製完整兩種情況。推論時間則使用 Python 的 time.time() 函數測量300張圖片的平均推論時間，若低於 0.03 秒標示極快，高於 0.03 秒標示快。

表 3-1 BlazePose、YOLO v11n - Pose、MoveNet-lightning 比較分析表

特徵	BlazePose (lite)	YOLO v11n - Pose	MoveNet - lightning
座標點數量	33個	17個	17個
範例	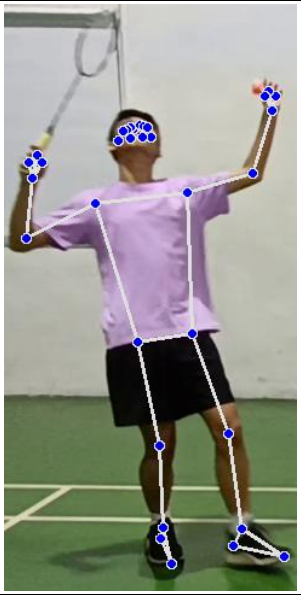		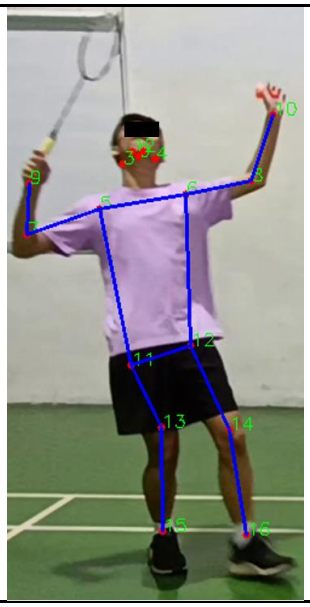
識別人數	單人	多人	多人
準確率	高	高	中
平均推論時間	快	快	極快

BlazePose 不僅提供四肢與軀幹的座標點，還包含腳趾與腳跟的位置資訊，並在手腕處額外提供三個座標點。由於這些特徵能更精確地捕捉羽球運動中的手部與腳步姿勢，本研究最終選擇 BlazePose 作為姿勢估計模型，以獲取更多可供分析的特徵點。

(二)座標點序列預處理方法

羽毛球運動是連續動作而非靜止狀態，球員在鏡頭前的位置及遠近，座標序列的絕對位置對於姿勢判定較無意義，因此將羽毛球姿勢骨架座標點序列進行相對位置的「中心化」預處理。首先，定義身體的中心點座標為是 11、12、23、24 座標點 x 與 y 值 的平均，接著再將每個座標點座標 (x_i, y_i) 減去此中心點，表示將全身的骨架圖形中心點位移至座標 (0,0) 位置。

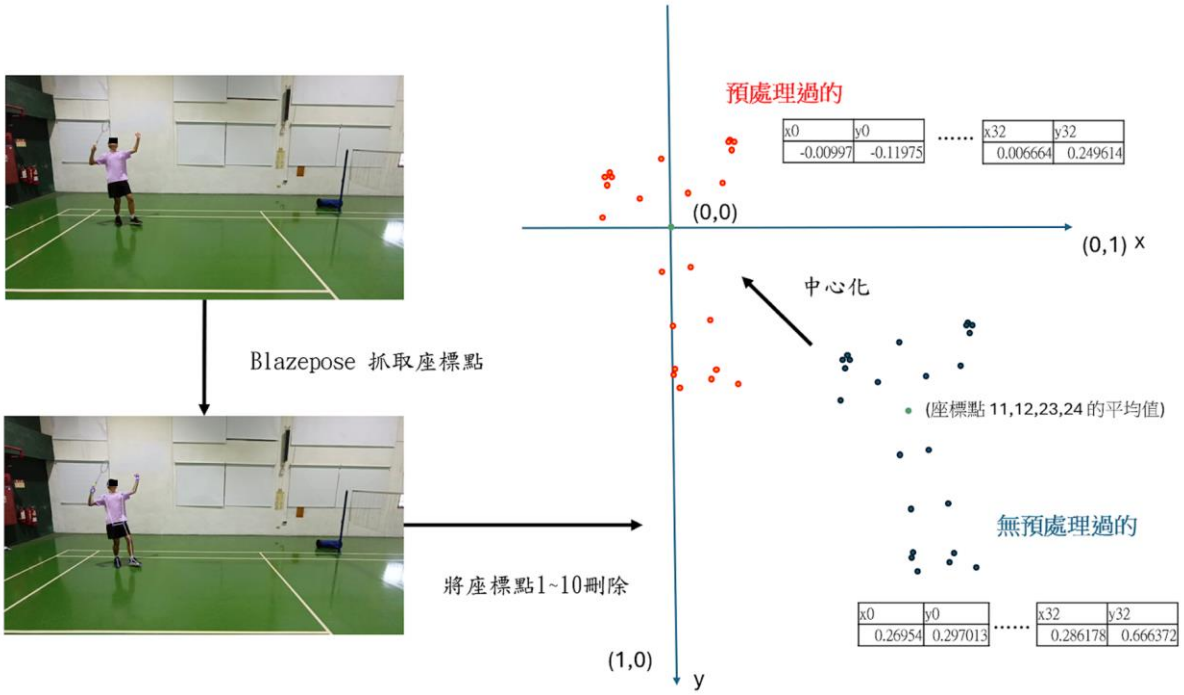

圖 3-8 人體骨架座標點序列的預處理示意圖

(三)姿勢分類器

在訓練模型前將座標點序列與姿勢標籤分開，再使用 scikit-learn 的 train_test_split() 函數將數據集拆分為訓練集和測試集。其中，約 80% (共 15,121 筆)用於訓練，剩餘約 20% (共 4,764 筆)則用於測試。本研究比較了全連接層(Multilayer Perceptron, MLP)、k-最近鄰(K- Nearest Neightbor, KNN)以及 YOLO 等模型的建置方式，以進行姿勢分類的評估，三種模型說明如下。

1.全連接層(MLP)：使用 Sequential 結構建置一個輸入層(Input Layer)三個隱藏層(Hidden Layer)及一個輸出層(Output Layer)。輸入層含 128 個神經元，並透過 BatchNormalization 穩定資料分佈加速收斂，且設定 ReLU為激活函數，並應用 30% 的 Dropout 防止過擬合。隱藏層逐層減少神經元數量(從 128 到 64，再到 32)，每層也搭配 BatchNormalization、 ReLU 激活函數以及適當的 Dropout。輸出層的神經元數對應分類類別數，並採用 Softmax 激活函數，將輸出轉換為機率分佈。最

後，採用 Adam 優化器和交叉熵損失函數(sparse_categorical_crossentropy)，並經過 100 個 epoch 的學習。

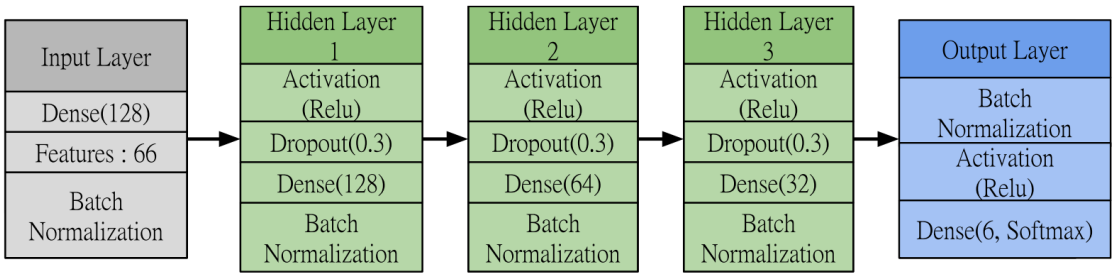

圖 3-9 MLP 模型架構

2.KNN： 本實驗使用的是 Scikit-learn 的 KNeighborsClassifier 。 k 值決定了在進行分類時，模型會參考k個最近的鄰居，本研究測試了不同的 k 值對模型表現的影響，研究者測試了從 1 到 50 不同的 k 值，並記錄每個 k 值下的訓練準確率和測試準確率。

3.YOLO： 本研究透過 BlazePose 姿勢估計模型與 opencv-python 繪製訓練資料的關節點及其連接，並為不同部位(如左右手、左右腿、身體)標記不同的顏色，接著再透過程式自動為 19,885 張圖片標記相應的 YOLO 格式 .txt 文件，其中包含物件類別、物件邊界框的中心點x與y座標及物件邊界框的寬度與高度。物件邊界框的中心點座標計算方式是取出所有座標點序列中最大與最小的 x 與 y 座標，命其為 x_{max}、x_{min}、y_{max}、y_{min}，再將其平均。如圖3-10為轉換公式。不同的姿勢類別定義如圖3-11。

$$Y = \frac{y_{max} + y_{min}}{2} \quad (2)$$

$$Y = \frac{y_{max} + y_{min}}{2} \quad (2)$$

$$W = x_{max} - x_{min} \quad (3)$$

$$H = y_{max} - y_{min} \quad (4)$$

圖3-10 轉換公式

```
1  names:
2    0: clear
3    1: drive
4    2: lift
5    3: net
6    4: other
7    5: serve
```

圖3-11 YOLO姿勢類別編號

如圖3-12展示關節點及其連接的 YOLO 格式標記資料轉換示意圖：

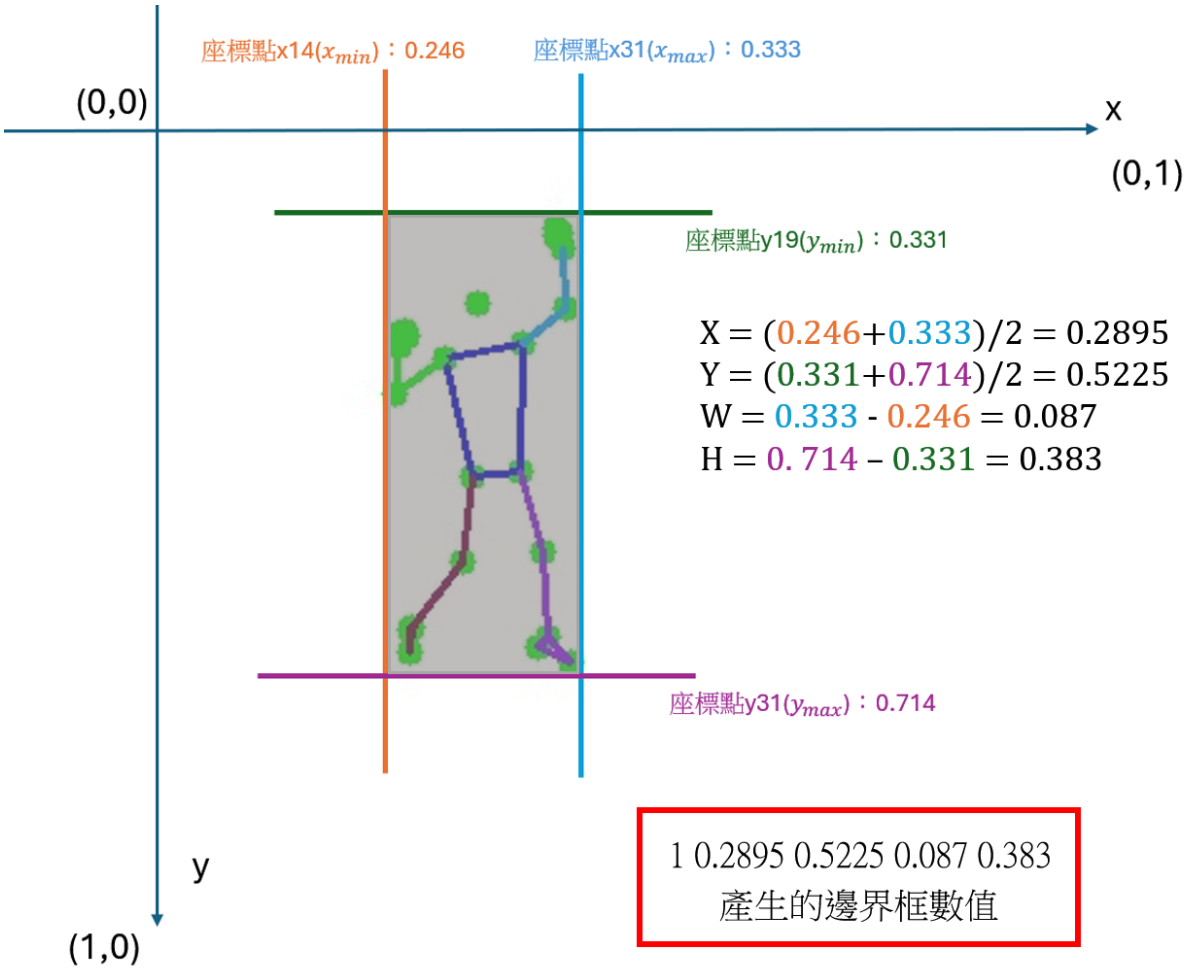

圖 3-12 YOLO標記資料自動轉換示意圖

如圖3-13所示本研究使用的參數為 100 個 epochs、img_size 256，以及 batch_size 32。

```
# Resume training
model.train(
    data='data.yaml', # Data Source
    epochs=100,       # Epochs for Training
    imgsz=256,        # Image Size for Training
    batch=32,         # Batch Size for Training
    device='0'        # Using GPU for Accelarating Training Process
)
```

圖 3-13 YOLO姿勢分類器訓練參數

(四)衡量指標

混淆矩陣用於評估分類模型性能的工具，通過比較實際值和預測值來展示結果，包含四個部分：

1.真陽性($True\ Positive$)：實際為目標類別，且被正確預測為目標類別的案例。

2.偽陰性($False\ Negative$)：實際為目標類別，但被錯誤預測為非目標類別的案例。

3.偽陽性($False\ Positive$)：實際為非目標類別，卻被錯誤預測為目標類別的案例。

4.真陰性($True\ Negative$)：實際為非目標類別，且被正確預測為非目標類別的案例。

表 3-2 混淆矩陣範例

	預測類別 1	預測類別 2	預測類別 3	預測類別 4	預測類別 5	預測類別 6
實際類別 1	$True\ Positive$	$False\ Negative$	$False\ Negative$	$False\ Negative$	$False\ Negative$	$False\ Negative$
實際類別 2	$False\ Positive$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$
實際類別 3	$False\ Positive$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$
實際類別 4	$False\ Positive$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$
實際類別 5	$False\ Positive$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$
實際類別 6	$False\ Positive$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$	$True\ Negative$

可以透過混淆矩陣的內容，來計算出衡量指標的前六項：

1.Accuracy： 所有類別的 $True\ Positve$ 除以總樣本數

2.Precision： $\frac{True\ Positive}{True\ Positive+False\ Positive}$ (精確率衡量預測為陽性的樣本中有多少實際是陽性)

3.Recall： $\frac{True\ Positive}{True\ Positive\ +False\ Negative}$ (召回率衡量實際為陽性的樣本中有多少被預測為陽性)

4.F1-score： $2\times\frac{Precision\times Recall}{Precision+Recall}$ (精確率和召回率的調和平均數)

5.macro avg：每個類別的 Precision、 Recall 和 F1-score 進行平均，類別的權重是相等的

6.weighted avg：每個類別的 Precision、Recall和 F1-score進行平均，進行加權

7.樣本數：分類模型測試的樣本

8.mAP@50： mAP@50 是物件偵測中評估模型準確度的指標，表示 IoU (預測框與真實框的重疊度)≥ 50% 時的平均精度

9.信心度：模型認為邊界框內含羽球的信心多寡，範圍為 0 至 1

10.YOLO 損失函數：包含cls_loss、dfl_loss、box_loss

11.FPS：計算一個模型從預處理到推論完成所花的時間的倒數

五、設計並實作 BIBO 方法應用於精確識別羽毛球動作分類的最佳時機

本研究提出 BIBO 方法可自動剪輯影片片段，以供羽毛球姿勢分類預測之用。如圖 3-14 所示，當羽毛球被偵測出現在鏡頭時，系統會開始收集影格，若鏡頭未偵測到羽毛球時，則開始計數若超過閾值 10 幀，模型則視球員已回擊球作為結束，BIBO 方法最後還會在開始及結束前後額外增加 5 幀確保捕捉足夠的影格數並據此剪輯影片 。

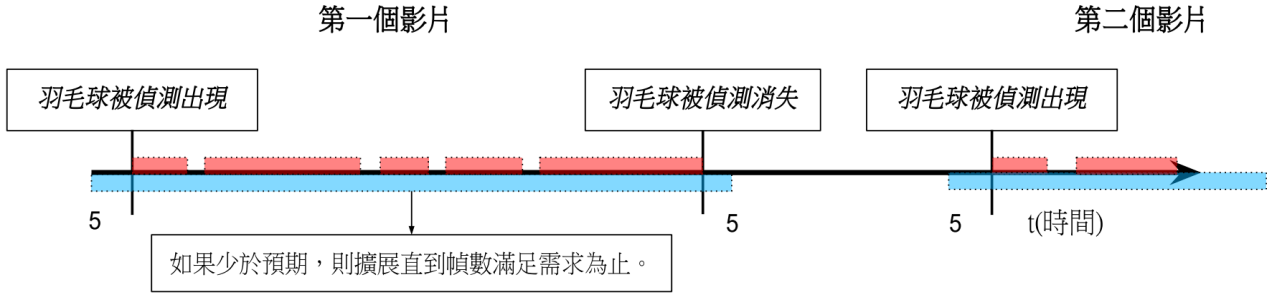

圖3-14 BIBO 偵測剪輯示意圖

本研究自行拍照並標記羽毛球影像，以此訓練 YOLO 模型，最終運用訓練完的 YOLO 模型進行羽毛球的自動偵測與追蹤。

(一) YOLO 模型訓練

追蹤羽毛球的 YOLO 模型將使用約 80% 的照片 (4,789張)來進行訓練，約20%的照片 (1,173張)來進行驗證。本研究同時使用兩種 YOLO 模型版本，YOLO v11n (Speed = 1.55 ms/mg，mAP 50-90 ： 39.5) 和 YOLO v11s (Speed = 2.63 ms/mg，mAP 50-90 ： 47)，並比較兩者性能表現。本研究使用的參數為 100 個 epochs、img_size 640，以及 batch_size 32。

```
model.train(
    data='data.yaml',    # Data Source
    epochs=100,          # Epochs for Training
    imgsz=640,           # Image Size for Training
    batch=32,            # Batch Size for Training
    device='0',          # Using GPU for Accelarating Training Process
    resume = True
)
```

圖 3-15 訓練參數

(二)TensorRT優化

TensorRT 旨在透過量化(Quantinization)等技術提升模型推理速度，例如將精度從 FP16 降至 INT8 減少計算成本，一般用來優化和加速神經網路模型在 NVIDIA GPU 上的執行時間。本研究使用 TensorRT 將模型從 .pt 格式 轉換為 .engine格式 ，以提升推理速度。

(三)衡量指標

為驗證 BIBO 流程是否準確且可行，本研究將研究者自行錄製的羽毛球比賽影片提供給 BIBO 進行剪輯處理，該影片包含 73 個打擊片段(7,803幀)，最後人工逐一檢查所有BIBO 剪輯的畫面，確認 BIBO 剪輯過的影片是否符合為一個完整羽球打擊動作，再計算其準確率評估是否可行。

1.Precision： 精確率衡量預測為陽性的樣本中有多少實際上是陽性

2.Recall： 召回率衡量實際為陽性的樣本中有多少被預測為陽性)

3.F1-score： 精確率和召回率的調和平均數

4.mAP@50： mAP@50 是物件偵測中評估模型準確度的指標，表示 IoU (預測框與真實框的重疊度)≥ 50% 時的平均精度。

5.信心度：模型認為邊界框內含羽球的信心多寡，範圍為0至1。

6.YOLO損失函數：包含 cls_loss 、 dfl_loss 、 box_loss 。

7.FPS：計算一個模型從預處理到推論完成所花的時間的倒數

六、研究如何整合各 AI 模型的分析結果並給予新手完善的姿勢建議。

(一)影片姿勢判定、常見錯誤姿勢修正及專家姿勢比對

本研究實驗六種羽毛球姿勢類別，每類姿勢各測試 15 段 BIBO 剪輯後的影片，由於影片是由連續幀畫面組成，在姿勢分類過程中，本研究利用三種姿勢分類模型對每一幀畫面進行獨立分類，並透過多數決策確定影片最終的姿勢類別(如圖3-16)。

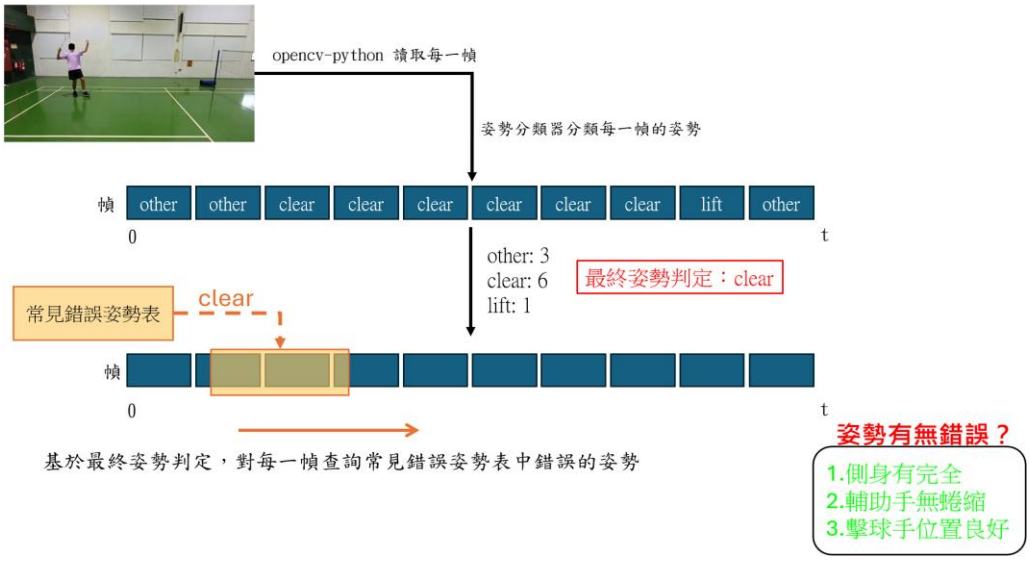

圖 3-16 影片姿勢判定

在姿勢類別判定後，我們將設計一個檢查函式(如圖 3-17 所示)，依據表1-1 檢查輸入影片中是否包含常見的錯誤姿勢，影片中將標示姿勢檢查結果，顯示是否存在錯誤。此外，本研究還會將這些檢查結果提供給 ChatGPT，以統整並提供錯誤姿勢的修正建議。

```
291            if pose_name == "lift":
292                angle_24_26_28 = angle(lmk, 24, 26, 28)
293                if lmk[32].x < lmk[31].x:
294                    P1_good=False
295                else:
296                    P1_good = True
297
298                if lmk[16].x > lmk[24].x:
299                    count += 1
300                else:
301                    P2_good = True
302
303                if angle_24_26_28 > 90 and lmk[26].x < lmk[32].x:
304                    count +=1
305                else:
306                    P3_good = True
307
308
309                overlay_text(image, "P1: Correct stance" if P1_good else "P1: Adjust foot position", (50, 50))
310                overlay_text(image, "P2: Good posture" if not P2_good else "P2: Adjust right hand", (50, 100))
311                if P1_good:
312                    overlay_text(image, "P3: Correct stance" , (50, 150))
313                else:
314                    overlay_text(image, "P3: Please Change your feet first", (50, 150))
```

圖 3-17 偵測動作錯誤函式(以挑球為例)

此外，本研究也對新手與專家的姿勢進行比對，首先記錄兩者的連續動作姿勢，接著繪製兩者的骨架圖，讓使用者直接觀察兩者的動作差異，進而識別偏差並改進。畫面中也會顯示使用者手部的揮拍軌跡，因為手部揮拍軌跡對新手的動作學習至關重要。

(二)LLM整合

LLM具有強大的語意理解及互動回饋能力，因此本實驗將利用大型語言模型進行姿勢建議的整合與重構，並透過 OpenAI 的 GPT-4 模型 進行 API 呼叫與執行，最後提供新手個人化的姿勢矯正建議。

```
54      client = openai.OpenAI(api_key=OPENAI_API_KEY)
55      response = client.chat.completions.create(
56          model="gpt-4",
57          messages=[
58              {"role": "developer", "content": f"{Text_User_Settings}"},
59              {"role": "user", "content": [
60                  {"type": "text",
61                   "text": prompt
62                  }
63              ]}
64          ]
65      )
66      return response.choices[0].message.content
```

圖 3-18 OpenAI 的API 呼叫

表 3-3 是本研究 ChatGPT 主要 API 呼叫的設定，{errors} 則是由常見錯誤姿勢偵測函數偵測出的項目名稱，{Pose_Errors} 是表1-1的項目內容。

表 3-3 ChatGPT提示詞設定

Text_User_ Settings	你是一名羽球專業教練，您會根據使用者描述的姿勢和使用者的錯誤給出建議以及改善的方法，{Pose_Errors}。
prompt	{errors}，請提供具體的調整建議。

(三)衡量指標

為評估 ChatGPT 提供的姿勢建議是否合適，本研究設計一套評分標準，包含清晰度、效果、相關性 及可行性四個面向，了解教練對 ChatGPT 姿勢建議的認同與滿意分數。測試內容包含 5 類新手學習的羽毛球姿勢，各 15 部影片 進行評估（總計 75 部影片，約 4,350 幀），最後收集三位羽球專家對 ChatGPT 在姿勢矯正建議上的認同分數。

表 3-4 教練對 ChatGPT 提供的姿勢建議的滿意程度評分標準

Question	Score	Description
清晰度	25	此建議容易理解嗎？
效果	25	此建議對錯誤姿勢問題解決有效嗎？
相關性	25	此建議與當前錯誤姿勢問題直接相關嗎？
可行性	25	此建議是否可行嗎？
合計	100	-

肆、研究結果及討論

一、探討人體姿態辨識模型及機器學習技術應用在羽毛球姿勢分類

本研究探討使用機器學習演算法(KNN)、深度學習(MLP)以及端對端深度學習(YOLO)等模型的原因，除了比較三種不同類型模型的表現外也瞭解其優化方式。研究結果顯示MLP搭配 Dropout 可以大幅提升模型的準確率，避免 MLP 過度擬和。使用 KNN 則能夠透過增加大量數據來幫助模型辨識姿勢，增加模型的準確率。而 YOLO 能夠理解姿勢的空間特徵，使姿勢判斷更準確。本實驗利用 15,121 筆座標點序列用於訓練，4,764 筆用於測試，三種模型訓練結果圖表資料如下。

(一) MLP 分類報告（ Accuracy = 99.52% ）

	精確率	召回率	F1-Score	樣本數
長球	0.9940	0.9955	0.9947	663
平球	0.9972	0.9931	0.9952	728
挑球	0.9935	0.9923	0.9929	775
放網	0.9979	0.9990	0.9984	958
其他	0.9909	0.9927	0.9918	551
發球	0.9967	1.0000	0.9983	302
宏觀平均	0.9951	0.9954	0.9952	3,977
加權平均	0.9952	0.9952	0.9952	3,977

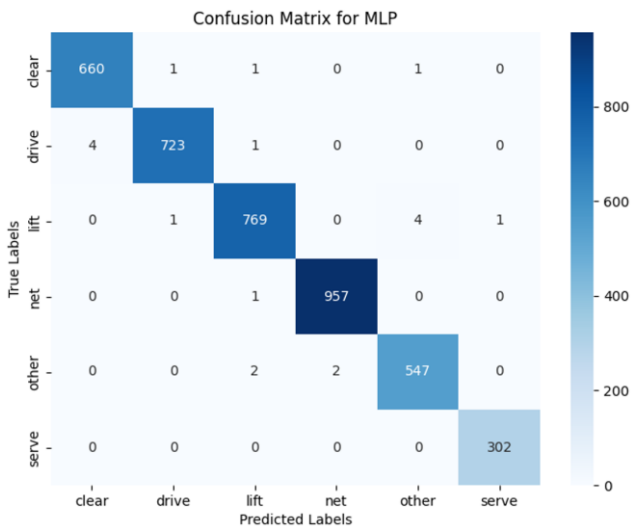

圖 4-1 MLP模型訓練完結果 - 混淆矩陣

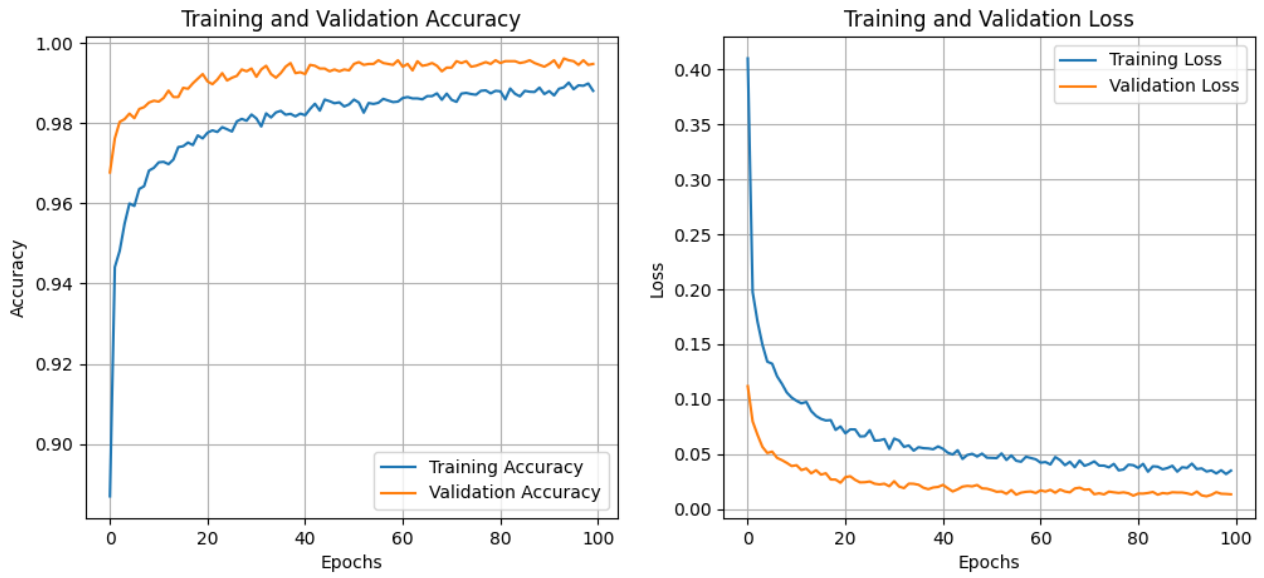

圖 4-2 MLP模型訓練完結果 - 訓練與驗證圖表

(二) KNN 分類報告 (Accuracy = 99.67%)

	精確率	召回率	F1-Score	樣本數
長球	0.9970	0.9925	0.9947	663
平球	0.9932	0.9986	0.9959	728
挑球	0.9974	0.9961	0.9968	775
放網	1.0000	1.0000	1.0000	958
其他	0.9945	0.9927	0.9936	551
發球	0.9967	1.0000	0.9983	302
宏觀平均	0.9965	0.9967	0.9966	3,977
加權平均	0.9967	0.9967	0.9967	3,977

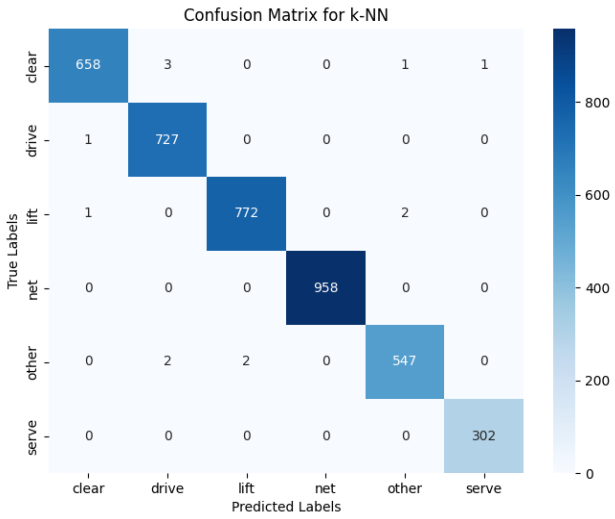

圖 4-3 KNN 模型訓練完結果 - 混淆矩陣

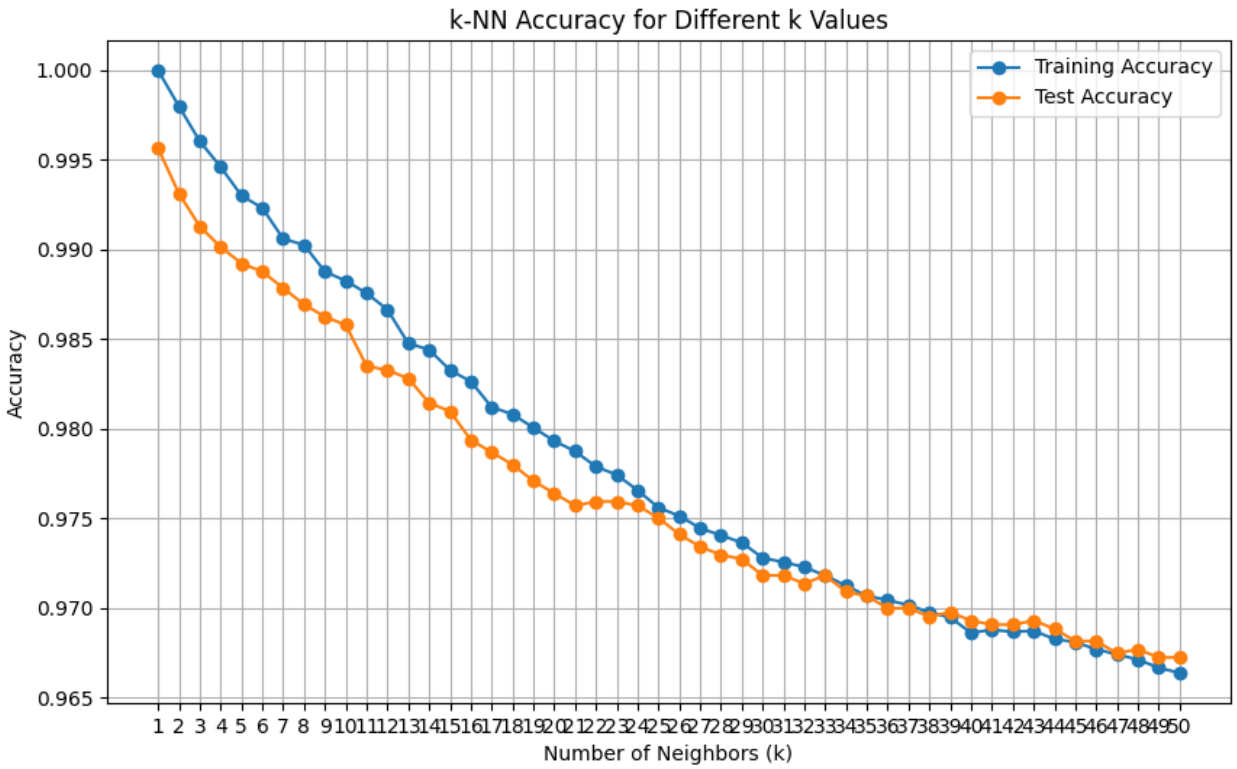

圖 4-4 KNN 模型訓練完結果 - 不同 k值和其訓練結果變化圖

(三) YOLO 分類報告 (Accuracy = 0.9960%)

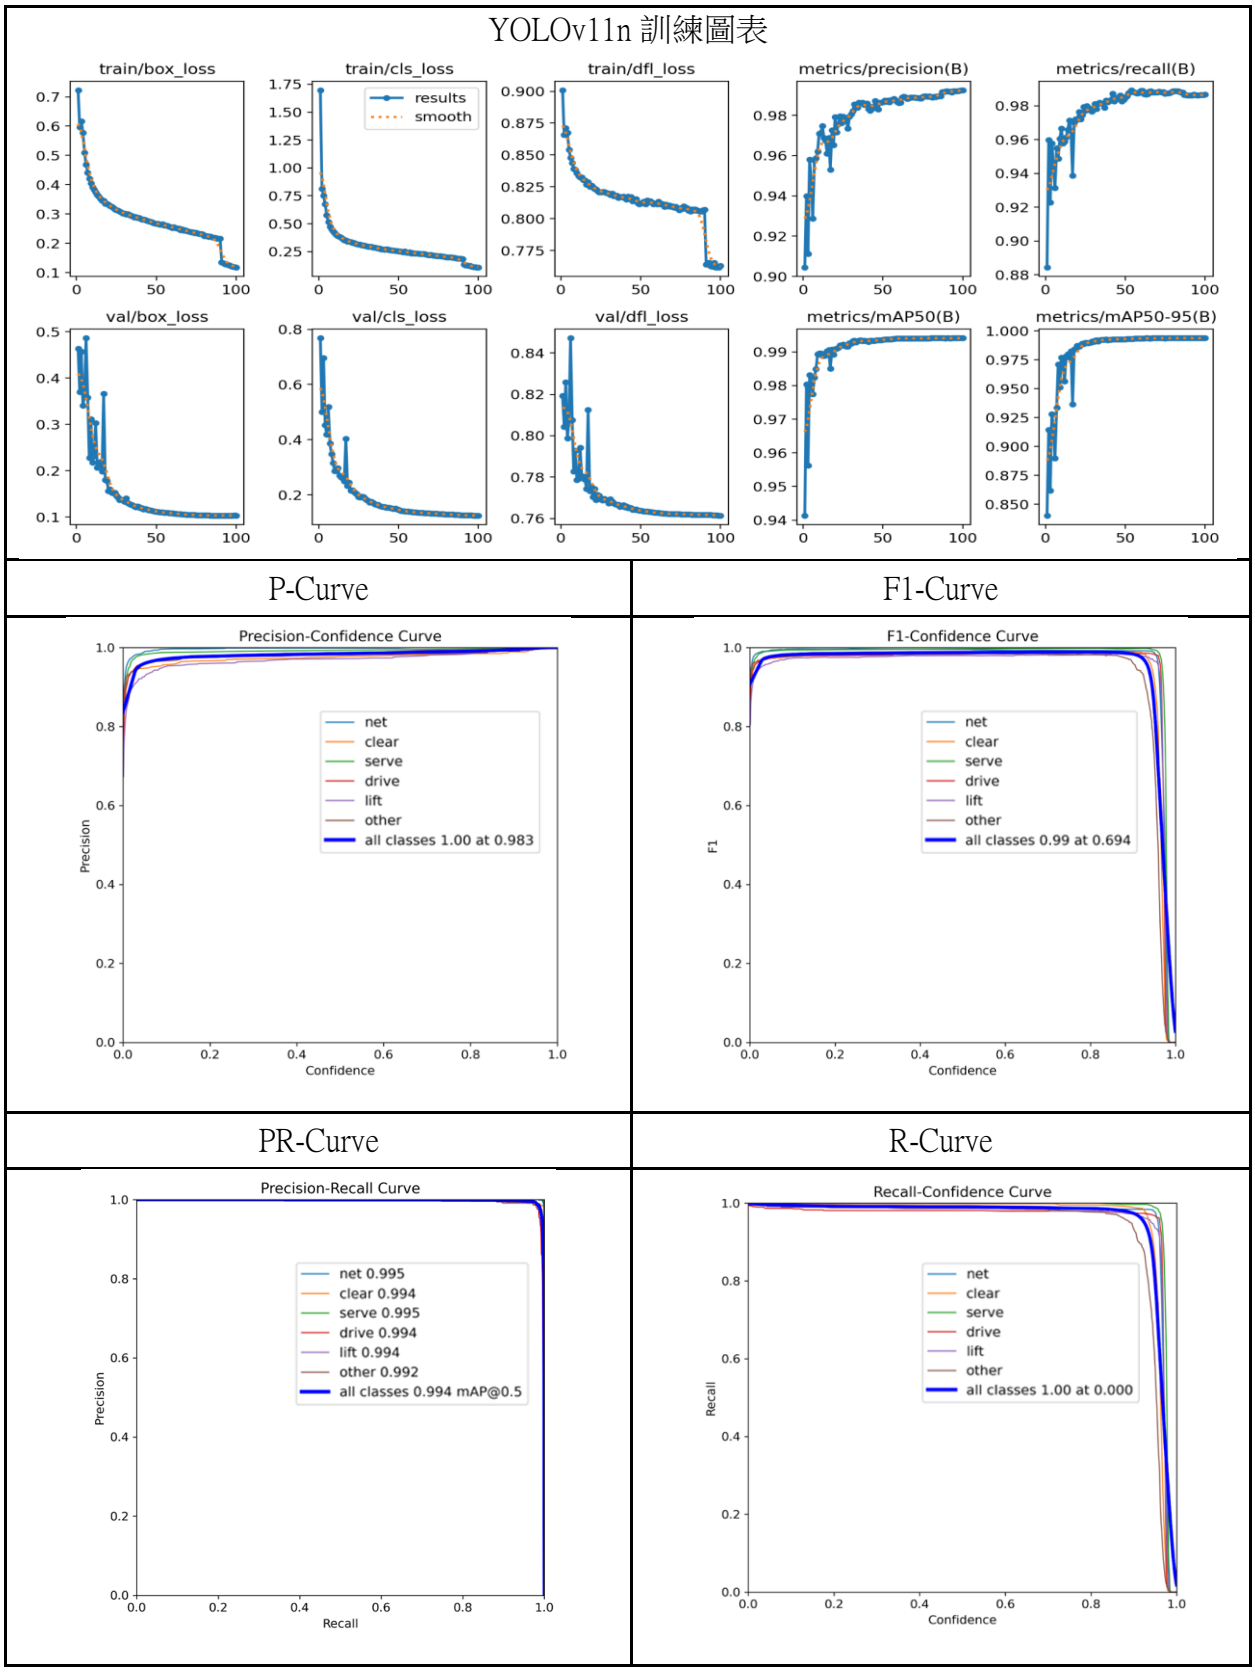

圖 4-5 YOLO v11n 模型訓練完結果 - YOLO 損失函數

```
Class     Images  Instances      Box(P          R      mAP50  mAP50-95):
  all       3977       3977      0.997      0.996      0.995      0.995
clear        704        704      0.995      0.996      0.995      0.995
drive        693        693      0.992      0.994      0.995      0.995
 lift        765        765      0.999      0.994      0.995      0.995
  net        952        952          1      0.999      0.995      0.995
other        545        545      0.998      0.994      0.995      0.995
serve        318        318      0.999          1      0.995      0.995
```

圖 4-6 YOLO 模型訓練完結果 - (Box Precision、Box Recall、mAP50、mAP50-95)

-	精確率	召回率	F1-Score	樣本數
長球	0.9943	0.9943	0.9943	704
平球	0.9899	0.9942	0.9920	693
挑球	0.9987	0.9948	0.9967	765
放網	1.0000	0.9989	0.9995	952
其他	0.9945	0.9945	0.9954	545
發球	0.9969	1.0000	0.9984	318
宏觀平均	0.9945	0.9945	0.9945	3,977
加權平均	0.9960	0.9960	0.9960	3,977

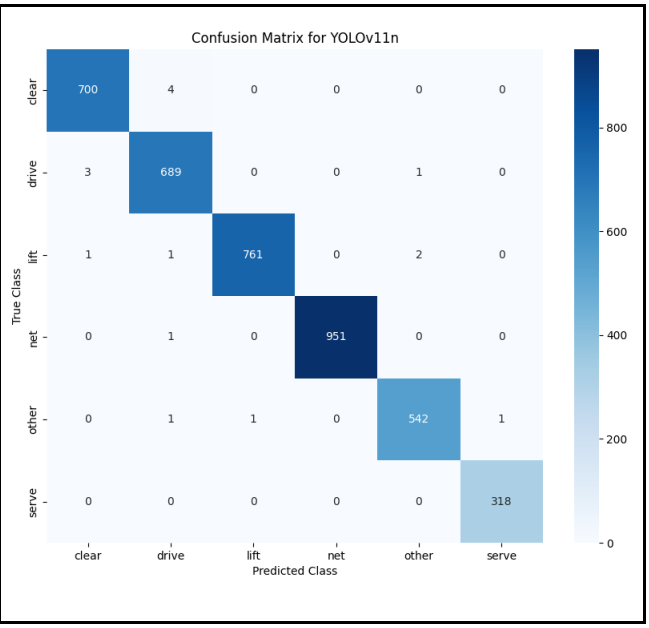

圖 4-7 YOLO 模型訓練完結果 - 混淆矩陣

綜合上述資料， KNN 模型精確率表現最佳為0.9967， 良好的原因與本研究提出數據前處理方法有關(人體姿勢座標點序列中心化)。此外，本研究也大量蒐集訓練資料，使 KNN 模型能夠準確分類。由於圖 4-4 中訓練和驗證的準確度差異不大，顯示並未有過擬合的現象，此外也可明顯看出，當 k = 1 時，模型表現最佳。KNN 模型易混淆的類別為平球與長球，其中長球 3 次被誤判為平球。

YOLO 模型精確率表現為0.9960，位居第二，YOLO 在信心度 0.983 的情況下，所有類別的精確率均達到 1.000 (詳見圖4-5)。經過 1.58 小時的訓練，YOLO 模型在多個姿勢類別上的表現均優異，mAP@50 更超過 0.99。YOLO 模型易混淆的類別是發球與長球，其中發球 7 次被誤判為長球（兩者收尾姿勢動作相似）。如 圖 4-8 所示，兩者外觀相近，唯一差異在於長球時手部位置較低。

圖 4-8 中 YOLO 模型的錯誤分析圖例

MLP 模型的分類表現排名第三，圖4-2 驗證損失(val loss)並未隨著訓練時間增加，代表 MLP 模型未出現過擬合現象，在 MLP 模型中，挑球與「其他」及挑球與平球最易混淆，各發生 4 次錯誤分類。挑球有時因預備動作相似被誤判為「其他」，而平球則可能被誤判為挑球。

二、設計並實作BIBO方法應用於精確識別羽毛球動作分類的最佳時機

本研究使用約80%的照片(4,789張)來進行訓練，約20%的照片(1,173張)來進行驗證。兩種 YOLO 模型版本訓練結果圖表資料如下。

(一)YOLO v11n

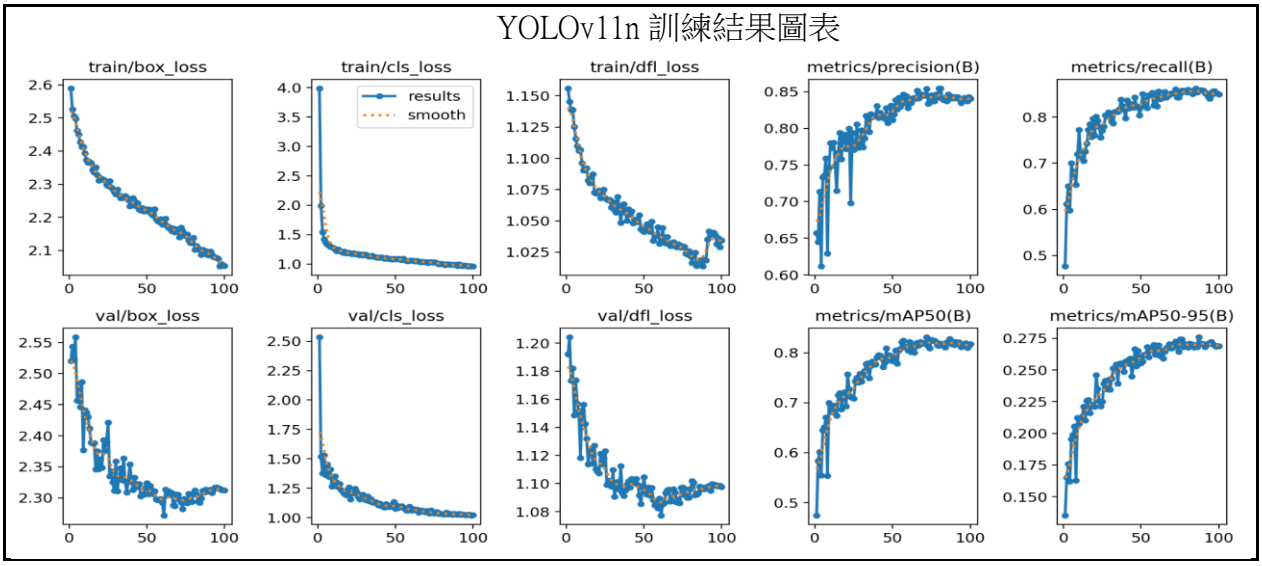

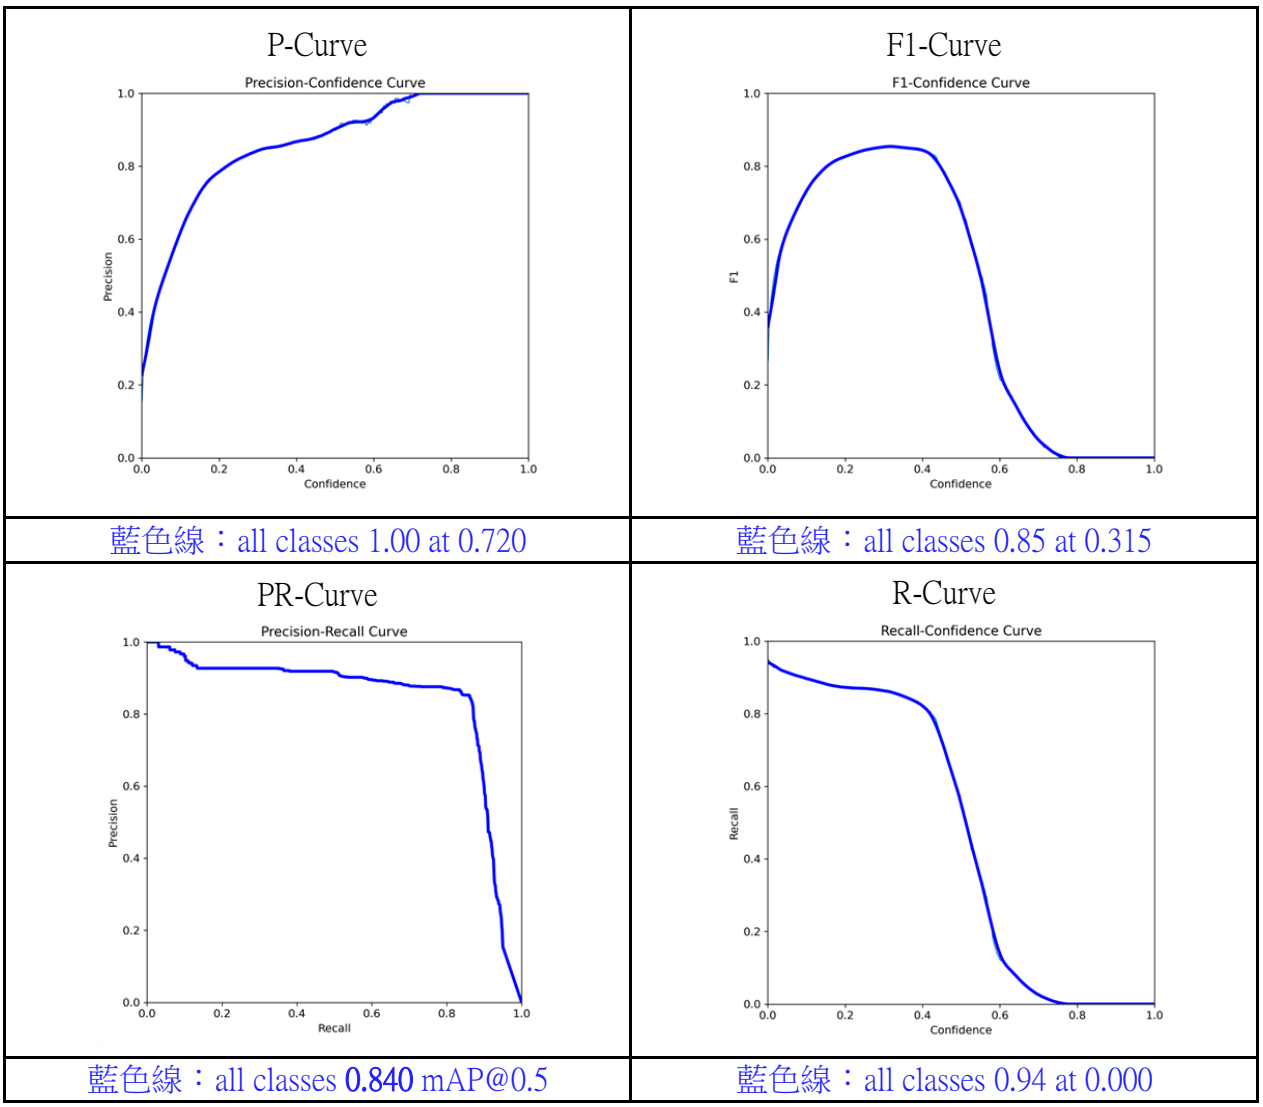

圖 4-9 YOLOv11n 訓練結果圖表

(二)YOLOv11s

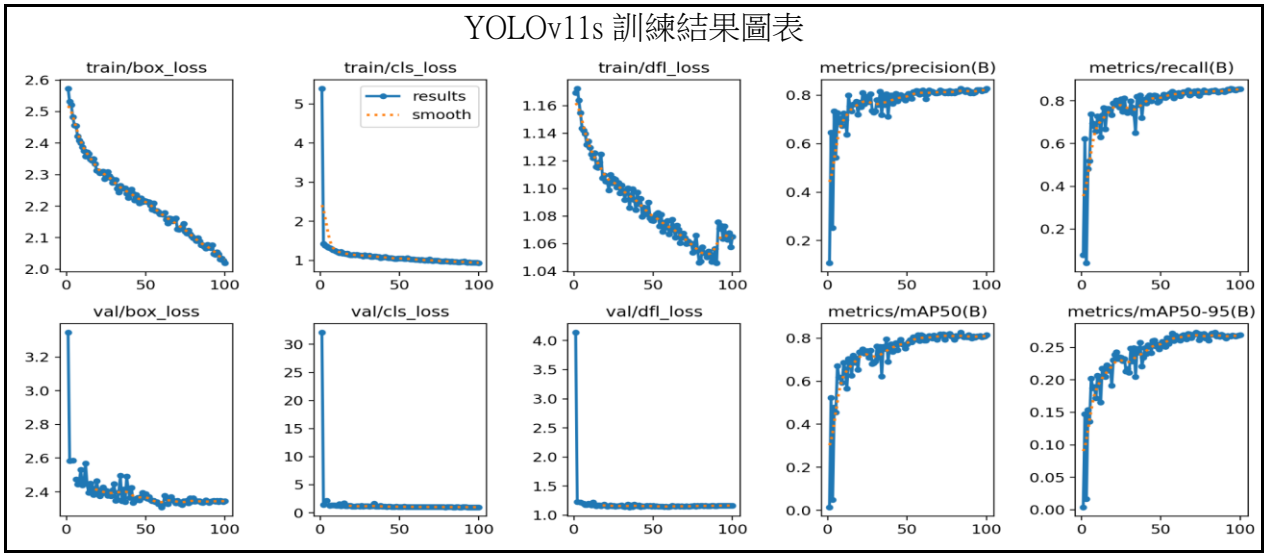

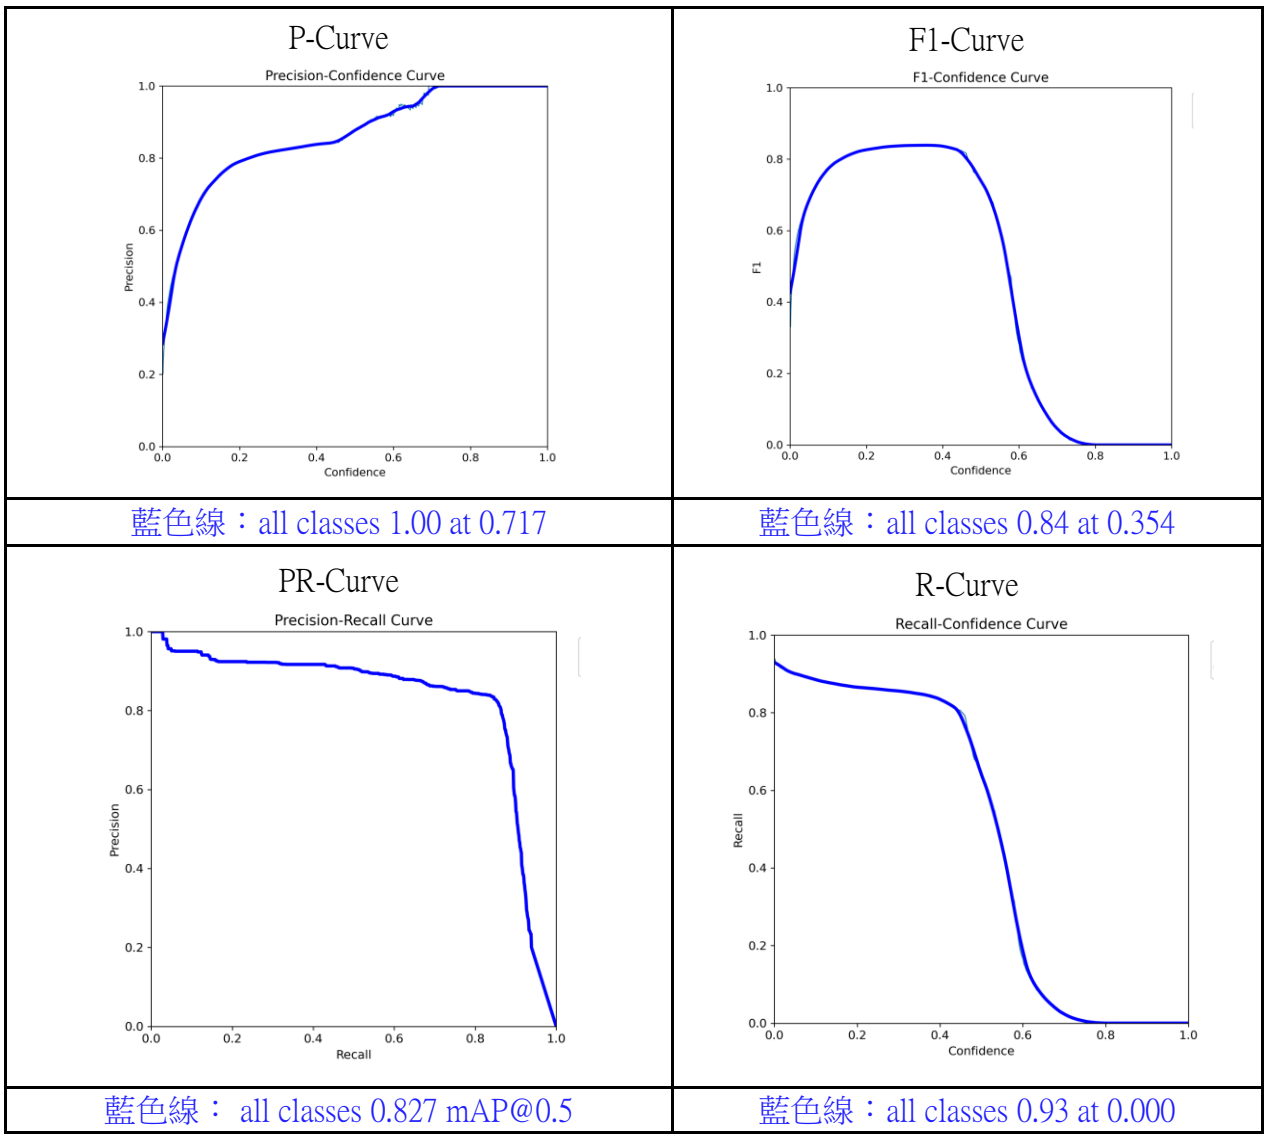

圖 4-10 YOLOv11s 訓練結果圖表

表 4-1 YOLO 模型在TensorRT量化前後比較

模型名稱	有TensorRT量化	無TensorRT量化
YOLO v11n	**70/73 (95.89%), 69.32FPS**	70/74 (94.59%), 61.40FPS
YOLO v11s	70/74 (94.59%), 65.57FPS	66/73 (90.41%), 62.95FPS

從表 4-1所見，四種模型皆能準確偵測羽球位置。其中，YOLO v11n 在 TensorRT 量化優化後，推理速度達 69.32 FPS，準確率 95.89%，不僅提升效能，更能即時流暢處理影片。儘管模型已具高準確率，使用 BIBO 追蹤羽球時仍可能發生以下兩類錯誤（如表 4-2）。

表 4-2 BIBO剪輯影片的問題

問題	敘述	圖例
問題一	當對手挑球位置太近，球雖出現在影片中但持續上升，超出手機鏡頭的捕捉範圍，導致球沒有被偵測到的幀數已超過閾值(10 幀)，使 BIBO 流程視為使用者已打擊完畢狀態，導致剪輯錯誤。	
問題二	當球拍移動太快時，羽球拍的中心部分的線材和羽毛球在高速運動的形狀非常相似，造成羽球偵測誤判。	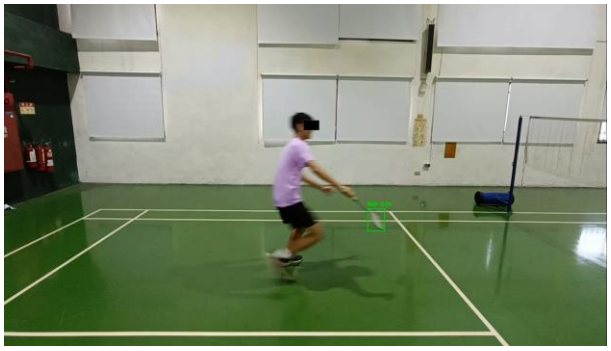

三、研究如何整合各 AI 模型的分析結果並給予新手完善的姿勢建議

本研究實測五種羽毛球姿勢，每種類別各15段 BIBO 剪輯影片，分類實測結果如下：

表 4-3 模型準確率評估(使用 75 部影片進行測試)

-	MLP	KNN	YOLO
長球	15/15(100.00%)	14/15(93.33%)	15/15(100.00%)
平球	15/15(100.00%)	15/15(100.00%)	15/15(100.00%)
挑球	11/15(73.33%)	13/15(86.67%)	12/15(80.00%)
放網	14/15(93.33%)	15/15(100.00%)	12/15(80.00%)
發球	15/15(100.00%)	15/15(100.00%)	15/15(100.00%)
總共	70/75(93.33%)	**73/75(97.33%)**	69/75(92.00%)

表 4-4 模型平均推理速度

模型名稱	MLP	KNN	YOLO
FPS	11.26	**25.48**	7.55

以上三個模型進行姿勢分類的準確率皆超過 90%。模型會產生錯誤的原因在於本研究使用測試的影片資料是透過 BIBO 自動剪裁，因此在某些影片中目標姿勢的幀數可能較少，特別是挑球姿勢，其中前段動作有時會被分類為發球，而結尾動作則可能被識別為平球。

根據表 4-3， KNN 具有最佳的準確率，而 YOLO 的準確率較低。考慮推論速度而言，從表 4-4 可看出 KNN 表現最佳，本研究不選擇 MLP 和 YOLO 在於 YOLO 需額外繪製圖像會大幅增加計算時間，而 MLP 也需要進行大量矩陣運算，其運算時間也是遠高於 KNN 。

下圖 4-11 是使用者與專家姿勢比對整合範例(以長球為例)，綠色骨架代表羽球專家的姿勢骨架，而白色骨架則是使用者的姿勢骨架，黃色線條為羽球專家的手部揮拍軌跡，而藍色線條則是使用者的手部揮拍軌跡，畫面中可直接觀察兩者的姿勢與手部揮拍軌跡差異有助於調整姿勢。此圖左上角也會顯示使用者目前姿勢的錯誤項目。紅色骨架線條也會輔助提醒使用者姿勢錯誤的地方。

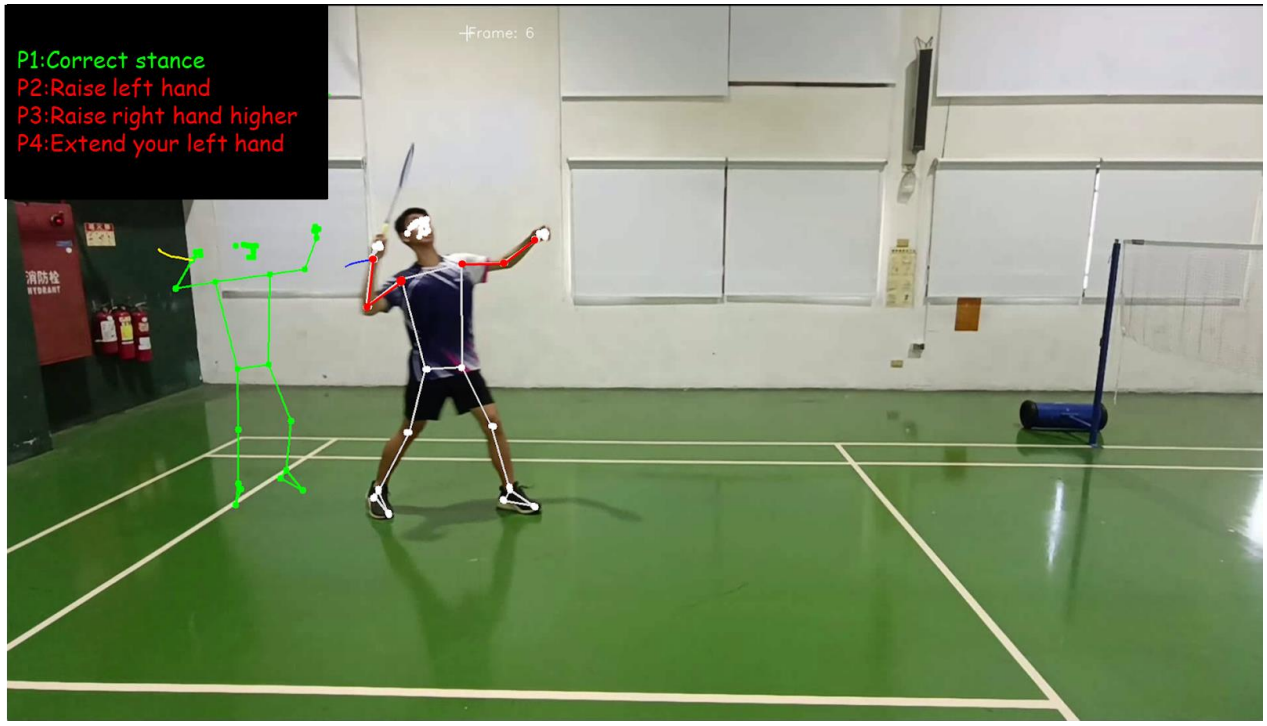

圖 4-11 修正整合範例(以長球為例)

表4-5是 ChatGPT 根據姿勢的錯誤項目所提供的建議範例(以長球為例)：

表 4-5 姿勢建議範例(以長球為例)

長球	**姿勢：**clear **錯誤：**輔助手蜷縮 擊球手位置過低 **此姿勢為何不好？** 1. 輔助手蜷縮會使你無法有效運用身體力量，在擊球時將可能力度不足。 2. 擊球手位置過低會導致你無法在最高點擊球，對於長球的傳遞與控制將會有困難。 **此姿勢如何改善？** 1. 要改善輔助手蜷縮的問題，你可以進行"身體旋轉練習"。緩慢地在前後方轉動身體，並確保身體始終正對著前方，藉此來增加身體轉動的範圍。此外，也可以嘗試"擴胸練習"，藉由張開胸部和展開手臂來調整輔助手臂的姿勢。 2. 如果擊球手位置過低，你可以進行"高點擊球練習"。朋友或教練用球拍向你高空打球，你要嘗試在高點擊球，並習慣這種擊球高度。同時也要明白，擊球的力量來源並非只有手腕，而是來自於全身的力量傳遞，要從腳底、腿、腰、背部、手臂、手腕順序傳遞出來。這樣才能有效提升長球的距離和準確度。

為評估 ChatGPT 提供的姿勢建議是否合適，本研究邀請3位羽球專家依據本研究設計的評分標準進行認同評分，表4-6為認同分數統計資料。

表 4-6 羽球專家對 ChatGPT 給新手姿勢建議的認同分數

	專家一	專家二	專家三	分數平均
清晰度	25	23	24	24.00
效果	20	18	21	19.67
相關性	20	21	20	20.33
可行性	19	19	20	19.33
總分	84	81	85	**83.33**

由上表可見，羽毛球專家對 ChatGPT 整合的姿勢建議給予 80 分以上的認同度，顯示其具備良好的可信度與專業性。羽球專家認為 ChatGPT 給出建議的清晰度非常高，容易理解，在效果方面雖然 ChatGPT 並無大多創新，但是對於使用者解決問題是有效的。

伍、結論

一、本研究三種姿勢分類器中，KNN 的表現最佳，影片的姿勢分類準確率達 97.33%。

二、本研究對於 KNN 姿勢分類器模型的**最佳 k 值為 1**。

三、本研究設計的 BIBO 方法，使用 TensorRT 量化後的 YOLOv11n 速度最快 (69.32FPS)，同時有最高的準確率 (95.89%)。

四、本研究 YOLO 羽毛球追蹤器經過 TensorRT 量化之後可以**稍微提升推論速度及準確率**。

五、本研究 ChatGPT 整合的姿勢建議效果良好，平均認同分數為83.33分。

六、未來可改進項目

(一)結合 IoT 設備，如透過智能手錶連接手機，當玩家姿勢不正確時，即時提供回饋。

(二)擴充賽事分析功能，例如戰術分析、各種球路擊球數、落點預測等。

陸、參考文獻資料

[1] Bazarevsky, V., Grishchenko, I., Raveendran, K., Zhang, F., Zhu, T., Grundmann, M., & Flynn, J. (2020). BlazePose： On-device real-time body pose tracking. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, 1004 – 1011. IEEE. https://arxiv.org/abs/2006.10204

[2] Huang, Y.-C., Huang, C.-H., Hsu, M.-H., & Lin, K.-C. (2019). TrackNet： A deep learning network for tracking high-speed and tiny objects in sports applications. *arXiv preprint arXiv：1907.03698*. https://arxiv.org/abs/1907.03698

[3] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once： Unified, real-time object detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. https://arxiv.org/abs/1506.02640

[4] Shiela, M. C. (2022). *Badminton strokes classification based on human pose estimation and machine learning* (Master’s thesis, National Taiwan University of Science and Technology). https://etheses.lib.ntust.edu.tw/thesis/detail/63ccf6a6d4ad0399ee9a48cf8311984a

[5] Toshniwal, D., Patil, A., & Vachhani, N. (2024). AI coach for badminton. *arXiv preprint arXiv：2403.08956*. https://arxiv.org/abs/2403.08956

[6] Wang, X., Wang, W., Yang, T., Wang, S., Zeng, J., & Liu, W. (2022). YOLO-Pose： Enhancing YOLO for multi-person pose estimation using object keypoint similarity loss. *arXiv preprint arXiv：2204.06806*. https://arxiv.org/abs/2204.06806

[8] Dollentas, N. (2023, October 15). *Clutch AI Badminton App review： Great idea, but does it deliver? (No)* [Video]. YouTube. https://www.youtube.com/watch?v=kfilVU56Jzw

[9] VICTOR 勝利體育。(n.d.)。*羽球教室*。https://www.victorsport.com.tw/badmintonaz.html

[10] 王文義、張凱聲、陳廷發、王正昌、彭文忠、易子文 (2020)。羽球教練AI：基於深度學習的羽球比賽數據分析平台。《體育學報》，53(2)，201－213。https://www.airitilibrary.com/Article/Detail/10247297-202006-202007060015-202007060015-201-213

[11] 科技大觀園. (2021, October 18). AI 讓羽球訓練更聰明！智慧球拍上手，揮拍「爆發力」一測就知道. *PanSci 泛科學*. https://pansci.asia/archives/332433

[12] Tukino, T., Pratiwi, M., & Defit, S. (2024). Deep learning based technical classification of badminton pose with convolutional neural networks. *ILKOM Jurnal Ilmiah*, *16*(1), 76－86. https://doi.org/10.33096/ilkom.v16i1.1951.76-86